

贝叶斯决策理论是统计模型决策中的基本方法

### 2.1 最小错误率贝叶斯决策

统计概率

先验概率：据历史资料或主观判断确定的各事件发生的概率，未佐证实

$$\text{条件概率} : P(A|B) = \frac{P(AB)}{P(B)}$$

贝叶斯公式：通过观察B把状态A的先验概率P(A)转化为后验P(A|B)

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

贝叶斯决策：在不完全情报下，对部分未知状态用主观概率估计，然后用

贝叶斯公式对发生概率进行修正，再利用期望值和修正概率做出最优决策

类条件概率密度函数似然


$$P(w_i|x) = \frac{P(x|w_i)P(w_i)}{P(x)}$$

最小错误率贝叶斯决策若  $P(w_i|x) = \max_{j=1, \dots, c} P(w_j|x)$ ，则  $x$  属于  $W_i$  类

$$\begin{cases} P(w_1|x) > P(w_2|x), x \in W_1 \\ P(w_1|x) < P(w_2|x), x \in W_2 \end{cases}$$

$$\begin{cases} ① P(w_1|x) > P(w_2|x), x \in W_1 \\ ② P(x|w_1)P(w_1) > P(x|w_2)P(w_2), \text{似然比阈值} \\ ③ L(x) = \frac{P(x|w_1)}{P(x|w_2)} > \frac{P(w_1)}{P(w_2)}, \text{似然比} \\ ④ h(x) = \ln L(x) = \ln P(x|w_1) - \ln P(x|w_2) = \ln \frac{P(x|w_1)}{P(x|w_2)} \end{cases}$$

判别函数与分类器：对多分类问题，设判别函数为  $g_i(x)$ ,  $i=1, \dots, c$ ，当  $g_i(x) > g_j(x)$ ,  $i \neq j$  时，分类器将  $x$  归为  $W_i$  类



决策面 方程应满足判别函数  $g_i(x) = g_j(x)$ ,  $i \neq j$  (两类相等) 相邻两个决策域在决策面上判别函数相等

分类的基本原理：不同模式映射点在特征空间的不同区域中分布，运用已知类别的训练样本进行学习。

产生若干代数界面  $g_i(x) = 0$ ，将特征空间划分为一些互不重叠的子区域

特征空间中点、直线、曲线、超曲面

\*为什么是最小错误率

分类平均错误率  $P(\text{error}) = \int_{-\infty}^{\infty} P(\text{error}, x) dx = \int_{-\infty}^{\infty} P(\text{error}|x) p(x) dx$

决策规则为  $P(w_i|x) = \max_{j=1, \dots, c} P(w_j|x)$ ,  $x \in W_i$  类

$\Rightarrow P(\text{error}|x) = 1 - \max_{j=1, \dots, c} P(w_j|x)$  对任一个可确保  $P(\text{error})$  最小，此时  $P(\text{error})$  最小

优点：对调查结果的可能性加以数量化的评价，输出非二值，而是置信度；

巧妙地将先验知识与具体观察这两种信息有机结合起来

缺点：需要的数据多，分析计算比较复杂；先验概率起决定作用，未考虑错误分类后果

### 2.2 最小风险贝叶斯

实际工作中不能仅仅考虑错误率，引入一个与损失有关的更广泛概念——风险

$$\text{条件风险 } R(\alpha_i|x) = E[\lambda(\alpha_i, w_j)]$$

$\leftarrow$  将  $x \in W_i$  样本视为  $W_j$  的损失,  $i \neq j$  时判断正确  
 $\leftarrow$  将  $x \in W_i$  的决策

有决策表

对给定  $x$  采用决策  $\alpha_i$ ，损失从  $c$  个  $\lambda(\alpha_i, w_j)$  中任意选择，其相应概率  $P(w_j|x)$ ，有：

	$w_1$	$w_2$	...	$w_i$	...	$w_c$
$\alpha_1$	$\lambda(\alpha_1, w_1)$	$\lambda(\alpha_1, w_2)$	...	$\lambda(\alpha_1, w_i)$	...	$\lambda(\alpha_1, w_c)$
$\alpha_2$	$\lambda(\alpha_2, w_1)$	$\lambda(\alpha_2, w_2)$	...	$\lambda(\alpha_2, w_i)$	...	$\lambda(\alpha_2, w_c)$
...	...	...	...	...	...	...
$\alpha_i$	$\lambda(\alpha_i, w_1)$	$\lambda(\alpha_i, w_2)$	...	$\lambda(\alpha_i, w_i)$	...	$\lambda(\alpha_i, w_c)$
...	...	...	...	...	...	...
$\alpha_n$	$\lambda(\alpha_n, w_1)$	$\lambda(\alpha_n, w_2)$	...	$\lambda(\alpha_n, w_i)$	...	$\lambda(\alpha_n, w_c)$


若  $R(\alpha_k|x) = \min_{i=1, \dots, n} R(\alpha_i|x)$ ，则对应决策  $\alpha_k$  判定  $x \in W_k$  类

X被判为  $W_k$  类时的平均损失，不同类其判别风险  $R(\alpha_i|x)$  大不相同

$$\begin{cases} ① R(\alpha_i|x) < R(\alpha_j|x) \\ ② C(\lambda_{21} - \lambda_{11})P(w_1|x) > C(\lambda_{22} - \lambda_{12})P(w_2|x) \\ ③ L(x) = \frac{P(x|w_1)}{P(x|w_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \frac{P(w_2)}{P(w_1)} \end{cases}$$

这两种决策方法之间的关系  $\Rightarrow$  基于最小错误率决策是基于最小风险决策的特例

损失函数  $\lambda(\alpha_i, w_j) = 1, i=j$  最小错误率决策退化为最小风险决策



### 2.3 Neyman-Pearson 决策与两类错误率

#### 1. 两类错误率

状态 (真实)	决策 (预测)	
	阳性	阴性
阳性	真阳性 (TP)	假阴性 (FN)
阴性	假阳性 (FP)	真阴性 (TN)

假阳性率  $\frac{\text{假阳性样本占总阳性样本比例}}{\text{总阳性样本}} \alpha = \frac{FP}{TP+FP}$

假阴性率  $\frac{\text{假阴性样本占总阴性样本比例}}{\text{总阴性样本}} \beta = \frac{FN}{TN+FN}$

灵敏度  $\frac{\text{阳性样本正确识别出来的能力}}{\text{总阳性样本}} S_n = \frac{TP}{TP+FN} = 1 - \beta$

特异度  $\frac{\text{阴性样本正确识别出来的能力}}{\text{总阴性样本}} S_p = \frac{TN}{TN+FP} = 1 - \alpha$

#### 2. Neyman-Pearson 决策

某些问题中一种错误比另一种错误重要，需在某约束条件下最小化总风险

Neyman-Pearson 原则：严格限制较重要的类错误概率为常数

而使另一类错误概率最小 → 常数

判决准则  $P(e) = \epsilon_0$  情况下使  $P(e)$  最小

对于二分类问题，可能发生两种错误

① 模式  $W_1$  被误分到  $W_2$

② 模式  $W_2$  被误分到  $W_1$

通过两种错误的概率分别为  $P_1(e)$  和  $P_2(e)$ ，有  $P_1(e), P_2(e), P(x|W_1), P(x|W_2)$

其中  $W_1$  和  $W_2$  对应区域  $I_1$  和  $I_2$ ，比较平均错误率定义

$$P(e) = P_1(e)P(W_1) + P_2(e)P(W_2) = P_1(e)\int_{I_1} P(x|W_1)dx + P_2(e)\int_{I_2} P(x|W_2)dx$$

运用 Lagrange 乘子法，取辅助函数  $L = P(e) + \lambda(P_2(e) - \epsilon_0)$

$$\begin{aligned} L &= P_1(e) + \lambda(P_2(e) - \epsilon_0) = \int_{I_2} P(x|W_2)dx + \lambda \left[ \int_{I_1} P(x|W_1)dx - \epsilon_0 \right] \\ &= \int_{I_2} P(x|W_2)dx + \lambda \int_{I_1} P(x|W_1)dx - \lambda \epsilon_0. \end{aligned}$$

设  $I_1$  和  $I_2$  的分界为  $t$ ，求使  $L$  最小的决策边界  $t$ ，求  $L$  偏导并令其为 0

$$\int \frac{\partial L}{\partial t} dt = 0 \quad \text{决策} \quad \int_{I_1} P(x|W_1)dx = \epsilon_0 \quad \text{约束}$$

$$\int \frac{\partial L}{\partial \lambda} dt = 0 \quad \text{边界上} \quad \lambda = \frac{P(x|W_1)}{P(x|W_2)}$$

得判决准则  $\Rightarrow$  令一类错误率为常数，使另一类错误率最小

$$\left| \frac{P(x|W_1)}{P(x|W_2)} \right| > \lambda, x \in W_1$$

$$\left| \frac{P(x|W_2)}{P(x|W_1)} \right| < \lambda, x \in W_2$$

由阈值决定

$$\left| \frac{P(x|W_1)}{P(x|W_2)} \right| \geq \lambda \quad \text{if } x \in I_1, \text{ then } x \in W_1 \\ \left| \frac{P(x|W_2)}{P(x|W_1)} \right| < \lambda \quad \text{if } x \in I_2, \text{ then } x \in W_2 \\ \text{min error} \quad \left| \frac{P(x|W_1)}{P(x|W_2)} \right| < \lambda, x \in W_2 \\ \text{min risk} \quad \left| \frac{P(x|W_1)}{P(x|W_2)} \right| > \lambda, x \in W_1$$

N-P 决策下的计算

令  $P(c|x)$  为似然比  $L(x)$  在条件  $x \in W_2$  下的概率密度，因  $L(x) > 1$  时

判定  $x \in W_1$ ， $\lambda$  可用下式判定

$$P_2(e) = \int_{\lambda}^{+\infty} P(c|x) dl = \epsilon_0$$

因  $P(c|x) \geq 0$ ,  $P_2(e)$  关于  $\lambda$  单调，可以使用试探法计算  $P_2(e) = \epsilon_0$  时的

$\lambda$ ，从而找使得  $P_2(e)$  尽量小

#### 3. ROC 曲线

$$ROC \text{ 曲线} \quad S_n = \frac{TP}{TP+FN} \quad S_p = \frac{TN}{TN+FP}$$

ROC 曲线：如果把灵敏度即真阳性率 ( $1 - P_1(e)$ )

作为纵坐标，假阳性率 ( $1 - S_p = P_2(e)$ ) 作为横坐标，可以获得随着决策面变化，两类错误率的变化情况。

1. 绘制方法：在类条件概率密度已知的情况下，可以通过求不同似然比条件下的两类错误率 ( $P_1(e) = \int_{I_1} P(X|\alpha_1) dX$ ,  $P_2(e) = \int_{I_2} P(X|\alpha_2) dX$ )，画出 ROC 曲线。

2. 用途：① 比较不同分类方法的性能

② 评估特征与类别的相关性度量

3. ROC 曲线比较：可以用 ROC 曲线下的面积即 AUC (Area under ROC curve) 来定量衡量方法的性能。

