

## 2.4 正态分布的统计决策

### 常为正态分布数学易处理

① 分类器决策面方程常涉及 条件概率密度  $P(X|W_i)$

1. 正态分布

$$\text{单变量: } p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]$$

$$\text{二项形式: } p(x) = (2\pi)^{-\frac{d}{2}} |\Sigma|^{-\frac{1}{2}} \exp\left[-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right]$$

多变量:  $p(x) = (2\pi)^{-\frac{d}{2}} |\Sigma|^{-\frac{1}{2}} \exp\left[-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right]$  称  $x$  服从  $d$  维正态分布, 记  $X \sim N_d(\mu, \Sigma)$

\* 式中  $x = [x_1, \dots, x_d]^T$ ,  $\mu = [\mu_1, \dots, \mu_d]^T$ ,  $\Sigma$  为协方差矩阵,  $\mu = E[x]$ ;  $\Sigma = E[(x-\mu)(x-\mu)^T]$ ,  $d \times d$  维协方差矩阵, 对称且正定,  $| \Sigma | > 0$

性质: ① 参数  $\mu$  和  $\Sigma$  决定分布形状  $d + \frac{d(d+1)}{2}$  个参数

② 等概率密度点轨迹为超椭球面,  $\mu$  为固定中心,  $\Sigma$  确定大小

\* 马氏距离  $r^2 = (x-\mu)^T \Sigma^{-1} (x-\mu)$ , 表示  $x$  的马氏距离平方, 等概率密度点轨迹是到  $\mu$  的距离为常数的超椭球面, 该超椭球体体积  $V = V_d |\Sigma|^{\frac{1}{2}} r^d$ , 其中  $V_d$  为单位超球体体积 =  $\frac{\pi^{\frac{d}{2}}}{\frac{d}{2} \pi^{(d-1)/2} (\frac{d-1}{2})!}$

③ 正态分布中不相关 = 独立性  $E[x_i x_j] = E[x_i] E[x_j]$   $\Leftrightarrow$  对角阵  
独立性  $P(x_i, x_j) = P(x_i) P(x_j)$  条件更强

④ 多元正态分布的边缘分布条件分布具有正态性

⑤ 线性变换的正态性  $y = Ax + N(A\mu, A\Sigma A^T)$

⑥ 线性组合的正态性  $y = a^T x$ ,  $N(a^T \mu, a^T \Sigma a)$

2. 正态分布概率模型下的最小错误贝叶斯决策

条件概率密度为正态分布  $P(X|W_i) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma_i|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i)\right]$

有判别函数  $g_i(x) = \ln P(X|W_i) - \ln P(X|W_j) = \ln P(X|W_i) + \ln P(W_i) - \frac{1}{2}((x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i)) - \frac{1}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(W_i)$

有决策面方程  $g_i(x) = g_j(x)$  或  $g_i(x) - g_j(x) = 0$  ( $i, j$  相邻)  $\Rightarrow -\frac{1}{2}(x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i) - (x-\mu_j)^T \Sigma_j^{-1} (x-\mu_j) - \frac{1}{2} \ln \frac{|\Sigma_i|}{|\Sigma_j|} + \ln \frac{P(W_i)}{P(W_j)} = 0$

米有如下讨论

①  $\Sigma_i = \sigma^2 I$ ,  $g_i(x) = -\frac{1}{2}((x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i)) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(W_i)$

各  $x_i$  离计量独立且方差相同  $\Rightarrow$  各样本在以  $\mu$  为中心同样大小的一些超球体中

此时  $|\Sigma_i| = \sigma^{2d}$ ,  $\Sigma_i^{-1} = \frac{1}{\sigma^2} I$ , 得 与类别无关

$$g_i(x) = -\frac{(x-\mu_i)^T (x-\mu_i)}{2\sigma^2} - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^{2d} + \ln P(W_i) \Rightarrow g_i(x) = -\frac{\|x-\mu_i\|^2}{2\sigma^2} + \ln P(W_i)$$

a. 若  $P(W_i) = P(W_j)$  先验等 待待分类向量分到欧氏距离最小类中,  $\min_{i=1, \dots, c} \|x-\mu_i\|^2$ , 最小距离分类器/模板匹配

b. 若  $P(W_i) \neq P(W_j)$

将欧式距离平方用  $\sigma^2$  规范化减去  $\ln P(W_i)$  再分类; 若待分类模式距两类均值向量距离等, 则将该模式分到先验大的那类 与分类无关且相等

对  $g_i(x) = -\frac{\|x-\mu_i\|^2}{2\sigma^2} + \ln P(W_i) = -\frac{1}{2\sigma^2} (x^T \Sigma_i^{-1} x + \mu_i^T \Sigma_i^{-1} \mu_i) + \ln P(W_i)$

$$\Rightarrow -\frac{1}{2\sigma^2} (x^T \Sigma_i^{-1} x + \mu_i^T \Sigma_i^{-1} \mu_i) + \ln P(W_i) = W_i^T x + w_{i0} \Rightarrow \text{线性判别函数, 线性分类器}$$

$$W_i = \frac{1}{\sigma^2} \mu_i, w_{i0} = -\frac{1}{2\sigma^2} \mu_i^T \Sigma_i^{-1} \mu_i + \ln P(W_i)$$

求决策面,  $g_i(x) - g_j(x) = 0$

$$\Rightarrow \frac{1}{\sigma^2} (\mu_i^T \Sigma_i^{-1} \mu_j - \mu_j^T \Sigma_j^{-1} \mu_i) + \ln \frac{P(W_i)}{P(W_j)} = 0$$

$$\| \mu_i - \mu_j \|^2 = (\mu_i - \mu_j)^T (\mu_i - \mu_j) \Rightarrow \frac{1}{\sigma^2} (\mu_i^T \Sigma_i^{-1} \mu_j - \mu_j^T \Sigma_j^{-1} \mu_i) + \frac{\sigma^2 (\mu_i - \mu_j)^T (\mu_i - \mu_j)}{\| \mu_i - \mu_j \|^2} \ln \frac{P(W_i)}{P(W_j)} = 0$$

$\Rightarrow W^T (x - x_0) = 0$  通过  $x_0$  正交于向量  $W$  的超平面

$$W = \mu_i - \mu_j, x_0 = \frac{1}{2} (\mu_i + \mu_j) - \frac{\sigma^2 (\mu_i - \mu_j)}{\| \mu_i - \mu_j \|^2} \ln \frac{P(W_i)}{P(W_j)}$$

均值向量间连线

a.  $P(W_i) = P(W_j)$  先验等

$x_0 = \frac{1}{2} (\mu_i + \mu_j)$ , 超平面通过  $\mu_i$  与  $\mu_j$  连线中点  $x_0$  与连线正交

b.  $P(W_i) \neq P(W_j)$  先验不等

$x_0$  不在中点, 走超平面向概率小一侧移动

(2)  $\sum_i = \sum_c$

各类协方差矩阵相等  $\Sigma_1 = \dots = \Sigma_c = \Sigma$ , 几何上相当于各类样本集中于以该类均值  $\mu_i$  为重心的同样大小和形状的超椭球体中。

判别函数  $g_i(x) = -\frac{1}{2} (x-\mu_i)^T \Sigma^{-1} (x-\mu_i) + \ln P(W_i)$

若  $c$  类先验概率相等 (即  $\ln P(W_i) = \ln P(W_2) = \dots = \ln P(W_c)$ ), 此时

$g_i(x) = (x-\mu_i)^T \Sigma^{-1} (x-\mu_i) = \|x - \mu_i\|^2$  - 马氏距离平方, 表示各种特性之间的联系

将样本划归到到均值点马氏距离最近的类中 独立于测量尺度

\* 为单位阵时, 马氏距离退化为欧式距离; 为对角阵时, 马氏

距离看正规化欧式距离

求决策面,  $g_i(x) - g_j(x) = 0$

$$\Rightarrow 2 \mu_i^T \Sigma^{-1} x + 2 \mu_j^T \Sigma^{-1} \mu_j - \mu_i^T \Sigma^{-1} \mu_i + (\ln P(W_i) - \ln P(W_j)) = 0$$

$$\Rightarrow 2 \mu_i^T \Sigma^{-1} x + \frac{\mu_i^T \Sigma^{-1} \mu_j - \mu_j^T \Sigma^{-1} \mu_i}{2 \mu_i^T \Sigma^{-1} \mu_j} + \frac{1}{2 \mu_i^T \Sigma^{-1} \mu_j} \ln \frac{P(W_i)}{P(W_j)} = 0$$

$\Rightarrow W^T (x - x_0) = 0$   $W$  与  $x - x_0$  正交, 决策面过  $x_0$

$$W = \sum_c \mu_i - \mu_j, x_0 = \frac{1}{2} (\mu_i + \mu_j) - \frac{(\mu_i - \mu_j)}{\mu_i^T \Sigma^{-1} \mu_j} \ln \frac{P(W_i)}{P(W_j)}$$

通常不在  $\mu_i - \mu_j$  方向上

a. 先验概率等, 交点在均值向量连线中点

b. 先验概率不等, 同小先验概率方向移动; 相差较大时, 判别边界不能落入球状分布中心点之间

(3)  $\Sigma_i \neq \Sigma_j, i, j = 1, 2, \dots, c$

$$g_i(x) = -\frac{1}{2} ((x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i)) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(W_i)$$

判别函数:  $g_i(x) = -\frac{1}{2} (x-\mu_i)^T \Sigma_i^{-1} (x-\mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(W_i)$

$$= x^T W_i x + w_{i0}$$

这是  $x$  的一个非线性二次形式

其中,  $W_i = -\frac{1}{2} \Sigma_i^{-1}$  ( $d \times d$ ) 矩阵,  $w_i = \Sigma_i^{-1} \mu_i$  ( $d$  维向量),  $w_{i0} = -\frac{1}{2} \mu_i^T \Sigma_i^{-1} \mu_i - \frac{1}{2} \ln |\Sigma_i| + \ln P(W_i)$

若决策域  $R_i$  和  $R_j$  毗邻, 则决策面方程为:

$$g_i(x) - g_j(x) = 0$$

$$x^T (W_i - W_j) x + (w_i - w_j)^T x + w_{i0} - w_{j0} = 0$$

其决策面是二次曲线(椭圆、双曲线、抛物线、一对直线), Bayes分类器是二次曲线分类器。

## 2.5 分类器错误率

1. 最小错误率贝叶斯决策的错误率  $P(e) = P(\omega_1) \int_{R_1} p(x|\omega_1) dx + P(\omega_2) \int_{R_2} p(x|\omega_2) dx$

$$= P(\omega_1) P_1(e) + P(\omega_2) P_2(e)$$

✓  $x$  为多维向量时, 要进行多重积分, 当概率密度表达式复杂时, 难于计算, 并且, 积分范围内判决区域的不连续也导致直接的计算困难。

错误率计算途径:

- (1) 理论计算
- (2) 计算错误率上界
- (3) 实验估计

### 2. 正态模式分类的错误率

见PPT

只要两类马氏距离足够大, 错误概率可足够小

$$P(e) = \int_{\mathbb{R}^d} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{|x-\mu|}{2}\right] dy$$

### 3. 独立随机变量错误率

$$P(e) = P(W_i) \Phi\left(\frac{\mu_i - \mu_j}{\sigma}\right) + P(W_j) [1 - \Phi\left(\frac{\mu_i - \mu_j}{\sigma}\right)]$$

$$\Phi(\mu) = \int_{-\infty}^{\mu} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{y^2}{2}\right] dy$$

## 2.6 离散概率模型统计决策

此时  $P(X|W_i)$  简化, 积分形式  $\int p(x|W_i) dx \Rightarrow \sum p(x|W_i)$ , 概率密度函数  $\Rightarrow$  概率分布函数

### 独立的二值特征

考虑两类问题, 其中特征向量的元素为二值的, 并且条件独立。

令  $x = (x_1, \dots, x_d)^T$ , 其中,  $x_i$  可能为 0 或 1, 且:

$$p_i = P(x_i = 1 | \omega_1) \quad q_i = P(x_i = 1 | \omega_2)$$

假设条件独立, 可将  $x$  元素的概率写为  $P(x | \omega)$ , 即

$$\begin{cases} P(x | \omega_1) = \prod_{i=1}^d p_i^{x_i} (1-p_i)^{1-x_i} \\ P(x | \omega_2) = \prod_{i=1}^d q_i^{x_i} (1-q_i)^{1-x_i} \end{cases}$$

那么似然比为

$$\frac{P(x | \omega_1)}{P(x | \omega_2)} = \prod_{i=1}^d \frac{p_i^{x_i} (1-p_i)^{1-x_i}}{q_i^{x_i} (1-q_i)^{1-x_i}}$$

独立的二值特征

基于最小错误率贝叶斯准则的判决函数  $g(x) = \ln \frac{P(x | \omega_1)}{P(x | \omega_2)}$

$$g(x) = \sum_{i=1}^d \ln \frac{p_i}{q_i} + (1-x_i) \ln \frac{1-p_i}{1-q_i} + \ln \frac{P(\omega_1)}{P(\omega_2)}$$

注意判决函数对  $x$  是线性的, 可改写为

$$g(x) = \sum_{i=1}^d w_i x_i + w_0 \quad \text{其中, } w_i = \ln \frac{p_i}{q_i} \quad i=1, \dots, d \quad w_0 = \sum_{i=1}^d \ln \frac{1-p_i}{1-q_i} + \ln \frac{P(\omega_1)}{P(\omega_2)}$$

若  $g(x) > 0$  判别为  $\omega_1$ , 否则为  $\omega_2$

- $g(x)$  可以看作是  $x$  的各分量的加权组合
- 特征独立的条件产生线性分类器, 而如果特征不独立将产生复杂的分类器