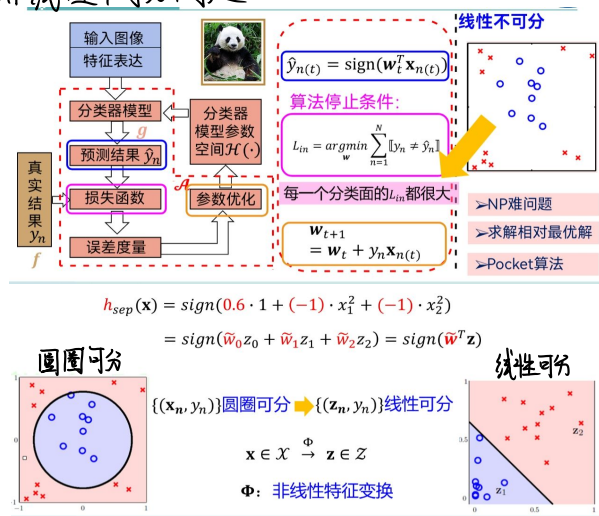


26.1 线性不可分问题



利用二次多项式的一般表达将样本 \mathbf{x} 从 \mathcal{X} 空间变换到 \mathcal{Z} 空间

$$\Phi_2(\mathbf{x}) = (1, x_1, \dots, x_d, x_1^2, x_1 x_2, \dots, x_d^2)^T$$

如果样本 \mathbf{x} 是 2 维特征, 则: $\Phi_2(\mathbf{x}) = (1, x_1, x_2, x_1^2, x_1 x_2, x_2^2)^T$

样本 \mathbf{x} 从原来的 d 维特征空间变换到多少维特征空间?

$$\begin{aligned} \tilde{d} &= 1 + d + d + C_d^2 = 1 + d + d + \binom{d}{2} \\ &= 1 + d + d + \frac{d(d-1)}{2} = 1 + \frac{d(d+3)}{2} = \frac{(d+2)(d+1)}{2} = \frac{(2+d)}{2} \end{aligned}$$

放回的组问题

利用 Q 次多项式的一般表达将样本 \mathbf{x} 从 \mathcal{X} 空间变换到 \mathcal{Z} 空间

$$\Phi_Q(\mathbf{x}) = (1, x_1, \dots, x_d, x_1^2, x_1 x_2, \dots, x_d^2, \dots, x_1^Q, x_1^{Q-1} x_2, \dots, x_d^Q)^T$$

一次项 二次项 Q 次项

样本 \mathbf{x} 从原来的 d 维特征空间变换到多少维特征空间?

$$\begin{aligned} \tilde{d} &= C_{Q+d}^Q = \frac{(Q+d)!}{Q! \cdot d!} = \frac{(Q+d-1)(Q+d-2) \cdots (Q+1)}{d!} \Rightarrow Q^d \end{aligned}$$


放回的组问题

非线性变换
使特征被升到
高维空间


26.2 非线性变换

目的: 通过非线性变换 Φ 使得训练样本集 $\{(z_n = \Phi(x_n), y_n)\}$ 在 \mathcal{Z} 空间找到好的分类面

非线性变换步骤



- 利用非线性变换 Φ 将原始训练样本集 $\{(x_n, y_n)\}$ 变换到 \mathcal{Z} 空间 $\{(z_n = \Phi(x_n), y_n)\}$;
- 在数据集 $\{(z_n, y_n)\}$ 上选择合适的线性分类算法 A , 得到最佳解 $\tilde{\mathbf{w}}^*$;
- 返回分类结果: $g(\mathbf{x}) = \text{sign}(\tilde{\mathbf{w}}^{*T} \mathbf{x})$



线性模型不局限于二元分类;
通过非线性变换, 可以方便地实现: 二次 PLA、三次 PLA、更高次数多项式的 PLA
二次回归、三次回归、更高次数回归。。。


特征提取

特征变换 Φ

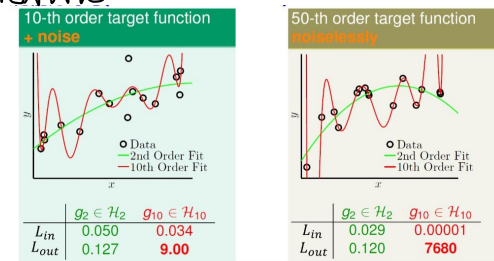
非线性变换并不一定是多项式变换

图像原始像素值
raw (pixels)

领域知识
domain
knowledge
具体特征
rete (intensity, symmetry)



26.3 泛化能力讨论



Vapnik-Chervonenkis (VC) Bound


For any $g = A(D) \in \mathcal{H}$ and 'statistical' large D , for $N \geq 2$, $d_{VC} \geq 2$

$$\mathbb{P}_D \left[\underbrace{|E_{in}(g) - E_{out}(g)|}_{\text{BAD}} > \epsilon \right] \leq \underbrace{4(2N)^{d_{VC}} \exp\left(-\frac{1}{8}\epsilon^2 N\right)}_{\delta}$$

VC 维度 (或 Vapnik-Chervonenkis 维度) 是衡量可以通过统计分类算法学习的函数空间的容量 (复杂度, 表现力, 丰富度或灵活性) 的度量。它被定义为算法可以破碎 (shatter) 的最大点集的基数

$$\begin{aligned} \dots, \text{ with probability } \geq 1 - \delta, \text{ GOOD: } |E_{in}(g) - E_{out}(g)| &\leq \epsilon \\ \text{set } \delta &= 4(2N)^{d_{VC}} \exp\left(-\frac{1}{8}\epsilon^2 N\right) \\ \frac{\delta}{4(2N)^{d_{VC}}} &= \exp\left(-\frac{1}{8}\epsilon^2 N\right) \\ \ln\left(\frac{\delta}{4(2N)^{d_{VC}}}\right) &= -\frac{1}{8}\epsilon^2 N \\ \sqrt{\frac{8}{N} \ln\left(\frac{4(2N)^{d_{VC}}}{\delta}\right)} &= \epsilon \\ \text{gen. error } |E_{in}(g) - E_{out}(g)| &\leq \sqrt{\frac{8}{N} \ln\left(\frac{4(2N)^{d_{VC}}}{\delta}\right)} \\ E_{in}(g) - \sqrt{\frac{8}{N} \ln\left(\frac{4(2N)^{d_{VC}}}{\delta}\right)} &\leq E_{out}(g) \leq E_{in}(g) + \sqrt{\frac{8}{N} \ln\left(\frac{4(2N)^{d_{VC}}}{\delta}\right)} \end{aligned}$$

$$E_{out}(g) \leq E_{in}(g) + \sqrt{\frac{8}{N} \ln\left(\frac{4(2N)^{d_{VC}}}{\delta}\right)} \quad \text{模型复杂度惩罚项 } \Omega(N, d_{VC}, \delta)$$



$d_{VC} \uparrow: E_{in} \downarrow, \Omega \uparrow$
 $d_{VC} \downarrow: \Omega \downarrow, E_{in} \uparrow$
 $\Rightarrow d_{VC}^*$ 在中间取到
此高不一定好

过拟合/泛化能力差: low E_{in} , high E_{out}

过拟合与正则化 (Overfitting and Regularization)

$$\min_{\mathbf{w}} E_{aug}(\mathbf{w}) = E_{in}(\mathbf{w}) + \frac{\lambda}{N} \|\mathbf{w}\|^2 \quad \text{正则项}$$

||w||² 防止 w 某维度数据过大

